پروژه درس آمار

فاز اول: شناخت مطالعه، داده و آمار توصیفی

نام دانشجو: پارمیدا داری پور
شماره دانشجویی: ۴۰۳۱۰۳۵۸۷

پاییز ۱۴۰۵

عنوان پروژه:
بررسی توصیفی ویژگی‌های جمعیت‌شناختی، شناختی و تصویربرداری مغزی در زیرمجموعه داده‌های NACC

مسیر انتخابی: NACC
ابزارهای تحلیل: Python و Pandas

مقدمه و هدف پروژه

بیماری آلزایمر یکی از بیماری‌های مرتبط با اختلالات شناختی است. بررسی ویژگی‌های جمعیت‌شناختی، وضعیت شناختی و اطلاعات تصویربرداری مغزی می‌تواند به شناخت بهتر جنبه‌های مختلف این بیماری کمک کند.

در این پروژه از مجموعه‌داده‌های مرکز ملی هماهنگی آلزایمر (NACC) استفاده می‌کنم. هدف فاز اول، آشنایی با ساختار داده‌ها، بررسی متغیرهای مهم و انجام تحلیل‌های آماری توصیفی است.

در این مرحله دو مجموعه‌داده اصلی بررسی می‌شوند: مجموعه اطلاعات بالینی و جمعیت‌شناختی (UDS) و مجموعه اطلاعات تصویربرداری مغزی (MRI). این دو مجموعه با استفاده از شناسه مشترک افراد، یعنی NACCID، به یکدیگر متصل می‌شوند.

در ادامه، متغیرهایی مانند سن، نمره ارزیابی شناختی و ویژگی‌های مربوط به ناحیه انتورینال مغز بررسی می‌شوند. همچنین کیفیت داده‌ها و ارتباط بین بعضی از متغیرها مورد بررسی قرار می‌گیرد.

۱ منشأ داده و سازوکار جمع‌آوری

منبع رسمی داده

داده‌های این پروژه از مسیر **NACC** صورت پروژه، یعنی مجموعهٔ National Alzheimer's Coordinating Center)، تأمین شده است. NACC مرکز هماهنگی مراکز آلزایمر (Alzheimer's Disease Centers) است که با پشتیبانی NIA/NIH داده‌های بالینی، شناختی، عصبی‌روان‌شناختی و تصویربرداری شرکت‌کنندگان را جمع‌آوری و یکپارچه می‌کند. منابع رسمی مورد استفاده شامل صفحهٔ عمومی دادهٔ NACC، فرم‌ها و مستندات (Data Forms and Documentation) و راهنمای پژوهشگر (Researcher Guide) است. دو فایل تحلیلی تحویل‌شده عبارت‌اند از `udslong_imputed.csv` (دادهٔ UDS) و `mriscanclean.csv` (ویژگی‌های MRI).

دورهٔ جمع‌آوری

در طراحی اصلی NACC، ارزیابی‌ها به‌صورت سالانه و چنددوره‌ای انجام می‌شوند. با این حال، در نسخهٔ تحویلی این پروژه تنها **یک رکورد به ازای هر شرکت‌کننده** در دسترس است و بازهٔ زمانی دقیق جمع‌آوری و تاریخ مراجعه در فایل‌ها مشخص نیست.

روش کلی تولید داده

داده‌ها حاصل یک **مطالعهٔ مشاهده‌ای چندمرکزی** هستند و نه کارآزمایی تصادفی‌شده. ارزیابی بالینی توسط ارزیابان آموزش‌دیده و بر اساس فرم‌های استاندارد UDS انجام می‌شود؛ برای زیرمجموعه‌ای از شرکت‌کنندگان نیز اسکن MRI ساختاری ثبت و با خط لولهٔ FreeSurfer پردازش می‌شود. اتصال دو وجه از طریق شناسهٔ مشترک `NACCID` انجام می‌گیرد. هیچ متغیری به‌صورت تصادفی تخصیص داده نشده و هیچ مداخله‌ای صورت نگرفته است.

محدودیت‌های دسترسی

- فقط دو فایل تحویلی تیم دستیاری در دسترس است، نه کل پایگاه NACC.
- دسترسی به دادهٔ کامل NACC مشروط به درخواست رسمی و قرارداد استفادهٔ داده است.

- بر اساس دستورالعمل درس، دادهٔ خام و حجیم نباید در مخزن GitHub قرار گیرد.

۲ واحد مشاهده و ساختار داده

یک ردیف داده نمایندهٔ چیست؟

در نسخهٔ تحویلی، **هر ردیف در فایل UDS و هر ردیف در فایل MRI نمایندهٔ یک شرکت‌کنندهٔ یکتا** است. فایل UDS شامل ۱۲۳۷ ردیف و ۱۲۳۷ شناسهٔ یکتای NACCID است (ردیف‌های با شناسهٔ تکراری = ۰؛ میانگین، کمینه و بیشینهٔ تعداد مراجعه به ازای هر شرکت‌کننده همگی برابر ۱). بنابراین برخلاف نام فایل، نسخهٔ تحویلی **در سطح شرکت‌کننده** و عملاً مقطعی است. فایل MRI نیز یک ردیف به ازای هر NACCID دارد.

آیا برای یک فرد چند ردیف وجود دارد؟

خیر. در این نسخه، هیچ فردی بیش از یک ردیف ندارد؛ ساختار سلسله‌مراتبی یا تکرارشونده در داده‌های تحویلی مشاهده نمی‌شود. جدول زیر این موضوع را خلاصه می‌کند:

شاخص	مقدار
ردیف‌های UDS	۱۲۳۷
شناسه‌های یکتای UDS	۱۲۳۷
ردیف‌های با شناسهٔ تکراری در UDS	۰
میانگین تعداد مراجعه به ازای هر شرکت‌کننده	۱
ردیف‌های MRI	۱۲۳۷
شناسه‌های یکتای MRI	۱۲۳۷
شرکت‌کنندگان مشترک در دو فایل	۱۲۳۷
UDS بدون MRI	۰
MRI بدون UDS	۰

جدول ۱: ساختار داده و جریان ادغام دو فایل.

از آنجا که هر دو فایل روی NACCID یکتا هستند، ادغام با `validate="one_to_one"` انجام و یکتایی نتیجه تأیید شده است.

۳ نمونه‌گیری، انتخاب و قابلیت تعمیم

سازوکار انتخاب

داده‌های NACC از شرکت‌کنندگانی به‌دست می‌آیند که به مراکز آلزایمر مراجعه کرده و رضایت آگاهانه برای مشارکت داده‌اند. این یک **نمونه‌گیری تصادفی از جمعیت عمومی** نیست؛ بلکه نمونه‌ای **مراجعه‌محور و داوطلبانه** از افراد حاضر در کلینیک‌های تخصصی است. بنابراین دو لایه انتخاب وجود دارد: (۱) انتخاب کردن برای مراجعه به مرکز آلزایمر، و (۲) انتخاب شدن برای ثبت MRI در زیرمجموعهٔ تصویربرداری.

آیا نمونه‌گیری تصادفی است؟

خیر. نمونه‌گیری تصادفی ساده (یا هر طرح نمونه‌گیری احتمالی که برای هر فرد شانس مشخصی از انتخاب تعریف کند) در تولید این داده به‌کار نرفته است. در نتیجه، برآوردهای خام این نمونه لزوماً برآوردهای نااریب پارامترهای جمعیت عمومی نیستند.

آیا مطالعه مشاهده‌ای است؟

بله. هیچ مداخله یا تخصیص تصادفی وجود ندارد و متغیرها در شرایط طبیعی و بالینی اندازه‌گیری شده‌اند. لذا رابطه‌های مشاهده‌شده را نباید به‌عنوان رابطهٔ علّی تفسیر کرد.

قابلیت تعمیم

نتایج این پروژه به‌طور دقیق به **همان جمعیت قابل تفسیر** یعنی «شرکت‌کنندگان مراجعه‌کننده به مراکز آلزایمر که در نسخهٔ تحویلی هم رکورد UDS و هم MRI دارند (۱۲۳۷ نفر)» محدود می‌شود. تعمیم به جمعیت عمومی سالمندان، یا حتی به کل شرکت‌کنندگان NACC، بدون شواهد اضافی دربارهٔ نمایندگی نمونه توجیه‌پذیر نیست.

۴ طبقه‌بندی متغیرها

متغیرهای اصلی و مقیاس اندازه‌گیری

فایل MRI در مجموع ۱۴۰ ستون دارد: برای ۳۵ ناحیهٔ قشری و زیرقشری در هر نیمکره، حجم مادهٔ خاکستری (*_GVOL، mm^3) و میانگین ضخامت قشر (*_AVGTH، mm) ثبت شده است. از این مجموعه، **متغیرهای منتخب پروژه** (بر اساس مبانی نظری درگیری ناحیهٔ انتورینال و پاراهیپوکامپ در آلزایمر) در جدول زیر آمده‌اند.

متغیر	بخش	نوع و مقیاس اندازه‌گیری	واحد
NACCAGE	UDS	کمی پیوسته	سال
SEX	UDS	اسمی دودویی	—
EDUC	UDS	کمی گسسته (سال)	سال
CDRSUM	UDS	کمی گسسته (۰–۱۸)	—
CDRGLOB	UDS	ترتیبی (۰–۳)	—
NACCUDSD	UDS	اسمی/ترتیبی	—
NACCGDS	UDS	کمی گسسته (۰–۱۵)	—
LH_ENTORHINAL_GVOL	MRI	کمی پیوسته	mm^3
RH_ENTORHINAL_GVOL	MRI	کمی پیوسته	mm^3
LH_ENTORHINAL_AVGTH	MRI	کمی پیوسته	mm
RH_ENTORHINAL_AVGTH	MRI	کمی پیوسته	mm
LH_PARAHIPPOCAMPAL_GVOL	MRI	کمی پیوسته	mm^3
RH_PARAHIPPOCAMPAL_GVOL	MRI	کمی پیوسته	mm^3

جدول ۲: متغیرهای اصلی و مقیاس اندازه‌گیری آن‌ها.

۵ ممیزی کیفیت داده‌ها

برای ارزیابی کیفیت داده‌ها، مجموعه‌داده‌های UDS و MRI از نظر داده‌های گمشده، کدهای ویژه، مقادیر غیرممکن، رکوردهای تکراری و ناسازگاری‌های منطقی بررسی شدند. ممیزی به‌صورت برنامه‌نویسی‌شده و با کد بازتولیدپذیر (src/audit.py) انجام شد. جدول‌های زیر خروجی این ممیزی را نشان می‌دهند.

جدول ۱: کدهای ویژه در فایل UDS

جدول زیر ستون‌هایی از UDS را که حداقل یک کد ویژه (8، 9، 88، 99، 888، 8888، 999، 9999) دارند نشان می‌دهد. ستون‌هایی با درصد کد ویژهٔ بالاتر از ۵۰٪ (مثل NACCOMS، NACCFMS، HALLSEV، NACCAMS، ELATSEV، DELSEV، MOTSEV، HISPOR، DISNSEV، DIABTYPE، APPSEV، APASEV، AGITSEV، HEARWAID، NITESEV، ANXSEV، IRRSEV، DEPDSEV، NACCAM، QUITSMOK، NACCFM، NACCOM) عمدتاً کد 9 دارند که در فرم‌های NACC به‌معنای «برای این فرد پرسیده نشد یا معنا نداشت» است؛ این ستون‌ها در تحلیل‌های این پروژه استفاده نمی‌شوند.

به‌طور خاص، متغیر HISPOR با ۹۳٫۸۶٪ کد 88 عملاً اطلاعات قابل‌استفاده‌ای ندارد و در تحلیل‌های این پروژه استفاده نمی‌شود.

ستون‌های مهم برای این پروژه (BPSYS، BPDIAS، HRATE، WEIGHT، EDUC، NACCAPOE) درصد کد ویژهٔ پایینی دارند و قابل تحلیل‌اند.

متغیر	n	n=8	n=9	n=88	n=99	n=888	n=999	درصد
BPDIAS	۱۲۳۷	۰	۰	۲۶	۴	۸۹	۰	۶۲.۹
HRATE	۱۲۳۷	۰	۰	۲	۰	۹۹	۰	۱۶.۸
WEIGHT	۱۲۳۷	۰	۰	۰	۲	۹۷	۰	۰.۰۸
BPSYS	۱۲۳۷	۰	۰	۱	۱	۸۹	۰	۳۶.۷
SMOKYRS	۱۲۳۷	۵	۲	۱۱	۱۱	۰	۰	۳۴.۲
HISPOR	۱۲۳۷	۰	۰	۱۱۶۰	۱	۰	۰	۸۶.۹۳
EDUC	۱۲۳۷	—	—	—	—	—	—	*
CDRSUM	۱۲۳۷	۰	۰	۰	۰	۰	۰	۰.۰
CDRGLOB	۱۲۳۷	۰	۰	۰	۰	۰	۰	۰.۰
NACCUDSD	۱۲۳۷	۰	۰	۰	۰	۰	۰	۰.۰

جدول ۲: کدهای ویژه در فایل MRI

در فایل MRI، کدهای ویژه به‌صورت 888، 8888، 999 و 9999 ظاهر شدند — یعنی همان کدهای «مقدار نامعلوم» در قالب مقادیر پیوسته. مجموع موارد کد ویژه در ۱۴ ستون، ۲۴ رکورد است (کمتر از ۰٫۰۵٪ از کل داده). این رکوردها باید پیش از تحلیل MRI به NaN تبدیل شوند، وگرنه میانگین و واریانس حجم‌ها به‌شدت منحرف می‌شوند.

جدول ۳: تصمیم برای هر نوع کد ویژه

داده‌های گمشده

هیچ سلول خالی به‌صورت NaN در فایل‌های تحویلی مشاهده نشد؛ با این حال، همان‌گونه که جدول‌های ۱ و ۲ نشان می‌دهند، دادهٔ گمشده به‌صورت کدهای ویژه ذخیره شده است. پس از تبدیل این کدها به NaN در فایل تحلیلی، درصد

متغیر	n	n=888	n=8888	n=999	n=9999
LH_TRANSVERSETEMPORAL_GVOL	۱۲۳۷	۳	۰	۲	۰
RH_PRECUNEUS_GVOL	۱۲۳۷	۰	۱	۰	۲
RH_TRANSVERSETEMPORAL_GVOL	۱۲۳۷	۱	۰	۲	۰
RH_LATERALORBITOFRONTAL_GVOL	۱۲۳۷	۰	۱	۰	۱
LH_ENTORHINAL_GVOL	۱۲۳۷	۰	۰	۱	۰
RH_ENTORHINAL_GVOL	۱۲۳۷	۱	۰	۰	۰
LH_INFERIORTEMPORAL_GVOL	۱۲۳۷	۰	۰	۰	۱
RH_INFERIORTEMPORAL_GVOL	۱۲۳۷	۰	۰	۰	۱
LH_INFERIORPARIETAL_GVOL	۱۲۳۷	۰	۰	۰	۱
LH_FUSIFORM_GVOL	۱۲۳۷	۰	۱	۰	۰
LH_PRECUNEUS_GVOL	۱۲۳۷	۰	۰	۰	۱
RH_LATERALOCCIPITAL_GVOL	۱۲۳۷	۰	۰	۰	۱
RH_SUPERIORPARIETAL_GVOL	۱۲۳۷	۰	۰	۰	۱
LH_SUPERIORPARIETAL_GVOL	۱۲۳۷	۰	۰	۰	۱
مجموع رکوردها	۲۴	۵	۲	۵	۱۰

جدول ۳: کدهای ویژهٔ شناسایی‌شده در فایل MRI.

گمشدهٔ واقعی هر متغیر محاسبه و در گزارش فاز اول برای متغیرهای اصلی (EDUC، NACCAGE، CDRSUM، NACCUDSD و متغیرهای منتخب MRI) گزارش خواهد شد.

مقادیر غیرممکن

پس از تبدیل کدهای ویژه، دو دسته مقدار غیرممکن باقی می‌ماند که در جدول ۱ به‌صورت مستقیم دیده نمی‌شوند و در ممیزی جداگانه بررسی شدند:

- **ترکیب غیرممکن قد و وزن:** در چند ردیف (مثلاً NACC074744، NACC186927) مقدار HEIGHT = 88.8 همراه با WEIGHT = 615 یا 888 مشاهده شد که پس از تبدیل به NaN، ردیف فقط در متغیرهای قد و وزن گمشده می‌شود و در سایر متغیرها قابل استفاده می‌ماند.
- **مقدار صفر در LH_ENTORHINAL_GVOL:** یک ردیف مقدار صفر دارد که ممکن است ناشی از خطای تقسیم‌بندی FreeSurfer، آتروفی شدید، یا خطای ثبت باشد.

رکوردهای تکراری و ادغام

فایل UDS شامل ۱۲۳۷ ردیف و ۱۲۳۷ شناسهٔ یکتای NACCID است (صفر ردیف تکراری). فایل MRI نیز ۱۲۳۷ شناسهٔ یکتا دارد. تطابق دو فایل کامل است (۰ در UDS بدون MRI، ۰ در MRI بدون UDS). ادغام با validate="one_to_one" انجام شد و مجموعهٔ نهایی ۱۲۳۷ شرکت‌کنندهٔ یکتا دارد.

ناسازگاری‌های منطقی

ناسازگاری بین NACCUDSD و CDRGLOB (مثلاً NACCUDSD = 1 با CDRGLOB = 3) به‌صورت هشدار ثبت می‌شود، اما ردیف حذف نمی‌شود؛ چون تشخیص بالینی و امتیاز CDR ممکن است به‌دلیل تفاوت در معیارها ناسازگار باشند و حذف خودکار، نمونه را سوگیری‌دار می‌کند.

کد	متغیر	تصمیم و دلیل
9 (یا 99)	عمومی	«پاسخ نداده / مرتبط نیست»؛ اگر متغیر در تحلیل استفاده شود، به NaN تبدیل می‌شود.
8 (یا 88)	عمومی	«نامعلوم»؛ در EDUC و سایر متغیرهای مورد استفاده، به NaN تبدیل می‌شود.
888 (یا 8888 یا 888.8)	HEIGHT، WEIGHT، HRATE، NACCBMI	کد «نامعلوم» در متغیرهای پیوسته؛ مقدار واقعی نیست و به NaN تبدیل می‌شود.
999 (یا 9999)	همان	«پاسخ نداده» در متغیرهای پیوسته؛ به NaN تبدیل می‌شود.
9 با فراوانی بالا	HALLSEV، ELATSEV، DELSEV، MOTSEV، APPSEV، APASEV، AGITSEV، ANXSEV، IRRSEV، DEPDSEV، NACCAM، NACCFM، NACCOM، NACCOMS، NACCFMS	«برای این فرد پرسیده نشد»؛ این ستون‌ها در این پروژه استفاده نمی‌شوند؛ اگر در آینده استفاده شوند، کد 9 به NaN تبدیل می‌شود.
NACCAPOE	NACCAPOE	«ژنوتیپ APOE اندازه‌گیری نشد»؛ برای تحلیل APOE در فازهای بعد، به NaN تبدیل می‌شود.
کدهای 999/888 در MRI	۱۴ ستون MRI	«مقدار نامعلوم» در حجم‌ها و ضخامت‌ها؛ به NaN تبدیل می‌شوند.

جدول ۴: تصمیم برای هر نوع کد ویژه و دلیل آن.

تصمیم نهایی

- دادهٔ خام دست‌نخورده می‌ماند؛ تمیزکاری در `src/clean.py` و پس از ممیزی اعمال می‌شود.
- کدهای ویژهٔ مستندشده (8، 9، 88، 99، 888، 8888، 999، 9999) در ستون‌های مورد استفاده در تحلیل، به NaN تبدیل می‌شوند (جدول ۳).
- هیچ ردیفی به‌دلیل کد ویژه یا مقدار غیرممکن از تحلیل حذف نمی‌شود؛ فقط مقدار متغیر مربوطه NaN می‌گیرد.
- مقادیر مشکوکِ غیرقطعی (صفر در LH_ENTORHINAL_GVOL، ترکیب قد و وزن غیرممکن) علامت می‌خورند.

۶ جداول فراوانی و توزیع تجربی

۰.۱ متغیرهای طبقه‌ای

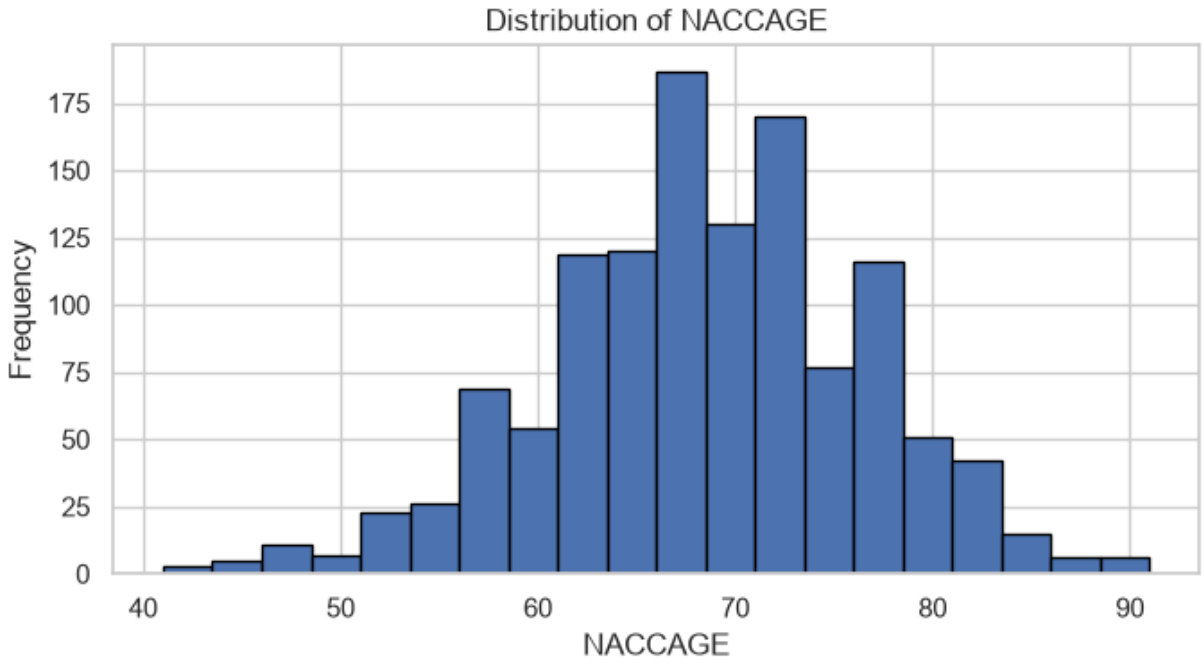
متغیر SEX (جنسیت): بر اساس جدول فراوانی، ۷۴۰ نفر (59.82%) در گروه ۲ و ۴۹۷ نفر (40.18%) در گروه ۱ قرار دارند. الگوی مهم: نمونه مورد بررسی نامتوازن است و اکثریت آن را گروه ۲ تشکیل می‌دهد.

متغیر NACCUDSD (وضعیت شناختی): ۸۴۷ نفر (68.47%) در گروه ۱ (سالم/طبیعی)، ۲۵۲ نفر (20.37%) در گروه ۳، ۱۳۱ نفر (10.59%) در گروه ۴ و تنها ۷ نفر (0.57%) در گروه ۲ قرار دارند. الگوی مهم: اکثریت قریب به اتفاق نمونه‌ها (بیش از دو سوم) در وضعیت شناختی طبیعی قرار دارند و گروه ۲ تقریباً نادر است (کمتر از ۱%).

متغیر CDRSUM (نمره زوال عقل): ۷۵۷ نفر (61.20%) نمره ۰.۰ دارند. با افزایش نمره، فراوانی به شدت کاهش می‌یابد (توزیع به شدت راست‌چوله). الگوی مهم: این متغیر نشان می‌دهد که بیشتر افراد هیچ نشانه‌ای از دمانس ندارند و تعداد بسیار کمی از افراد نمرات بالا (نشان‌دهنده زوال شدید) دارند.

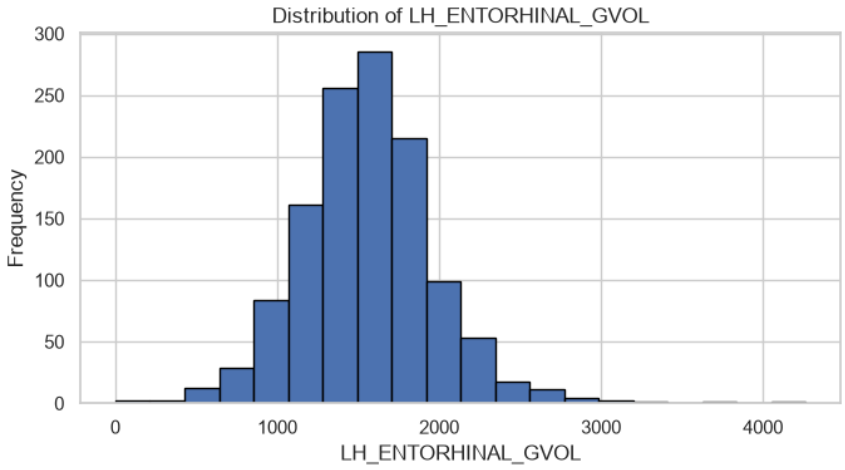
۰.۲ متغیرهای کمی

متغیر NACCAGE (سن): میانگین سن ۱۹.۶۸ سال (انحراف معیار ۰۴.۸) و میانه ۶۸ سال است. دامنه سنی از ۴۱ تا ۹۱ سال متغیر است. الگوی مهم: هیستوگرام سن تقریباً زنگوله‌ای (نرمال) است و اکثر افراد در بازه ۶۰ تا ۷۵ سال قرار دارند. میانه و میانگین بسیار نزدیک هستند که نشان‌دهنده تقارن توزیع است.



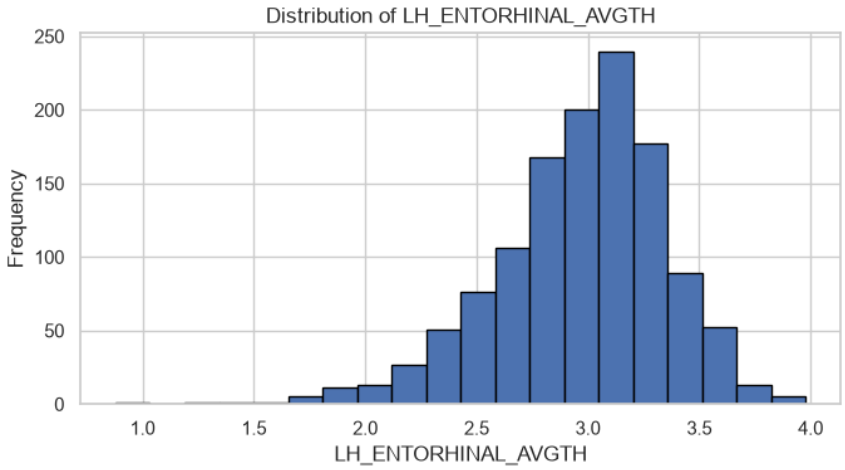
شکل ۱: توزیع فراوانی متغیر NACCAGE (سن)

متغیر LH_ENTORHINAL_GVOL (حجم ناحیه آنتورینال): میانگین ۲۸۰۱۵۵۴ (انحراف معیار ۵۲۰۴۱۳) و میانه ۱۵۴۵ است. الگوی مهم: هیستوگرام تقریباً متقارن و زنگوله‌ای است، اما مقادیر حداقل ۰ و حداکثری ۴۲۶۵ نشان می‌دهد که داده‌های پرت (Outliers) وجود دارند. بیشترین تمرکز داده‌ها در بازه ۱۳۰۰ تا ۱۸۰۰ است.



شکل ۲: توزیع فراوانی متغیر LH_ENTORHINAL_GVOL

متغیر LH_ENTORHINAL_AVGTH (ضخامت ناحیه آنتورینال): میانگین ۹۷۰۲ (انحراف معیار ۳۸۰۰) و میانه ۰۲۰۳ است. الگوی مهم: توزیع این متغیر تقریباً نرمال است و بیشتر داده‌ها در بازه ۷۰۲ تا ۴۰۳ متمرکز شده‌اند.



شکل ۳: توزیع فراوانی متغیر LH_ENTORHINAL_AVGTH

متغیرهای EDUC (تحصیلات) و NACCGDS (افسردگی): متغیر EDUC دارای حداکثر ۹۹ است که نشان‌دهنده کدگذاری خاص "نامشخص" است و باید در تحلیل‌های بعدی حذف یا اصلاح شود. NACCGDS نیز به شدت راست‌چوله است (میانه ۱ در برابر میانگین ۰۱۰۲) که نشان می‌دهد اکثر افراد نمره افسردگی پایینی دارند.

۷ مرکز و پراکندگی

- **توزیع متقارن (نرمال):** میانگین و انحراف معیار معیارهای مناسبی هستند.
- **توزیع چوله (Skewed) یا دارای داده‌های پرت:** میانه و دامنه بین‌چارکی (IQR) مقاوم‌تر و مناسب‌تر هستند، زیرا میانگین به شدت تحت تأثیر مقادیر پرت قرار می‌گیرد.

۰۱ متغیرهای اصلی

متغیر NACCAGE (سن):

- **میانگین:** ۱۹.۶۸ **میانه:** ۰۰.۶۸
- **انحراف معیار:** ۰۴.۸
- **چارک اول :(Q۱)** ۰۰.۶۳ **چارک سوم :(Q۳)** ۰۰.۷۴
- **دامنه بین‌چارکی :(IQR)** $74.00 - 63.00 = 11.00$

الگوی مهم: میانگین و میانه بسیار نزدیک هستند و توزیع تقریباً زنگوله‌ای است؛ بنابراین **میانگین و انحراف معیار** معیارهای مناسبی برای مرکز و پراکندگی سن هستند.

متغیر EDUC (تحصیلات):

- **میانگین:** ۳۹.۱۶ **میانه:** ۰۰.۱۶
- **انحراف معیار:** ۲۹.۴
- **چارک اول :(Q۱)** ۰۰.۱۴ **چارک سوم :(Q۳)** ۰۰.۱۸
- **دامنه بین‌چارکی :(IQR)** $18.00 - 14.00 = 4.00$

الگوی مهم: وجود مقدار ۹۹ (کد خطا یا داده پرت) باعث می‌شود میانگین و انحراف معیار گمراه‌کننده شوند. بنابراین، **میانه و IQR** برای این متغیر مناسب‌تر هستند.

متغیر NACCGDS (نمره افسردگی):

- **میانگین:** ۰۱.۲ **میانه:** ۰۰.۱
- **انحراف معیار:** ۹۰.۵
- **چارک اول :(Q۱)** ۰۰.۰ **چارک سوم :(Q۳)** ۰۰.۲
- **دامنه بین‌چارکی :(IQR)** $2.00 - 0.00 = 2.00$

الگوی مهم: میانگین (۰۱.۲) بزرگ‌تر از میانه (۰۰.۱) و انحراف معیار (۹۰.۵) بسیار بزرگ است؛ توزیع به شدت راست‌چوله است. بنابراین، **میانه و IQR** مناسب‌ترند.

متغیر CDRSUM (نمره زوال عقل):

- **میانگین:** ۸۲.۰ **میانه:** ۰۰.۰
- **انحراف معیار:** ۷۲.۱
- **چارک اول :(Q۱)** ۰۰.۰ **چارک سوم :(Q۳)** ۰۰.۱
- **دامنه بین‌چارکی :(IQR)** $1.00 - 0.00 = 1.00$

الگوی مهم: بیش از ٪۶۱ افراد نمره ۰ دارند؛ توزیع به شدت راست‌چوله است. بنابراین، **میانه و IQR** مناسب‌تر از میانگین هستند.

متغیر LH_ENTORHINAL_GVOL (حجم ناحیه آنتورینال چپ):

- **میانگین:** ۲۸.۱۵۵۴ **میانه:** ۰۰.۱۵۴۵
- **انحراف معیار:** ۵۲.۴۱۳
- **چارک اول :(Q۱)** ۰۰.۱۲۹۵ **چارک سوم :(Q۳)** ۰۰.۱۷۸۵
- **دامنه بین‌چارکی :(IQR)** $1785.00 - 1295.00 = 490.00$

الگوی مهم: میانگین و میانه نزدیک‌اند، اما مقادیر حداقل ۰ و حداکثری ۴۲۶۵ (داده‌های پرت) باعث شده‌اند گزارش **میانه و IQR** در کنار میانگین تصویر کامل‌تری بدهد.

متغیر LH_ENTORHINAL_AVGTH (ضخامت ناحیه آنتورینال چپ):

- **میانگین:** ۹۷.۲ **میانه:** ۰۲.۳
- **انحراف معیار:** ۳۸.۰
- **چارک اول :(Q۱)** ۷۶.۲ **چارک سوم :(Q۳)** ۲۳.۳
- **دامنه بین‌چارکی :(IQR)** $3.23 - 2.76 = 0.47$

الگوی مهم: توزیع تقریباً نرمال و متقارن است؛ بنابراین **میانگین و انحراف معیار** کاملاً مناسب هستند و IQR نیز به‌عنوان معیار مکمل قابل گزارش است.

۰۲. متغیرهای تکمیلی

متغیر LH_PARAHIPPOCAMPAL_GVOL (حجم پاراهیپوکامپال چپ):

- **میانگین:** ۷۱.۲۰۳۶ **میانه:** ۰۰.۲۰۱۹
- **انحراف معیار:** ۸۹.۳۸۷
- **چارک اول:** ۰۰.۱۷۹۱ **چارک سوم:** ۰۰.۲۲۵۷
- **دامنه بین‌چارکی :(IQR)** ۰۰.۴۶۶

الگوی مهم: میانگین و میانه نزدیک‌اند (تقارن نسبی)؛ اما حداقل ۱۶۷ و حداکثر ۵۱۳۶ نشان‌دهنده داده پرت است. گزارش **میانگین/انحراف معیار همراه با میانه/IQR** توصیه می‌شود.

متغیر RH_PARAHIPPOCAMPAL_GVOL (حجم پاراهیپوکامپال راست):

- **میانگین:** ۲۴.۱۹۱۱ **میانه:** ۰۰.۱۹۰۳
- **انحراف معیار:** ۹۶.۳۴۴
- **چارک اول:** ۰۰.۱۷۱۸ **چارک سوم:** ۰۰.۲۰۹۰

- **دامنه بین‌چارکی :(IQR)** ۰۰.۳۷۲

الگوی مهم: مشابه نیم کره چپ؛ تقارن نسبی با وجود داده‌های پرت در دو انتها (۷۴ و ۶۳۳۵).

متغیر LH_PRECUNEUS_GVOL (حجم پرکونئوس چپ):

- **میانگین:** ۶۸.۸۴۹۵ **میانه:** ۰۰.۸۵۲۱
- **انحراف معیار:** ۱۹.۱۴۱۶
- **چارک اول:** ۰۰.۷۶۹۸ **چارک سوم:** ۰۰.۹۳۳۶
- **دامنه بین‌چارکی :(IQR)** ۰۰.۱۶۳۸

الگوی مهم: توزیع تقریباً متقارن؛ اما حداقل مقدار ۱۲۴ باید به‌عنوان داده پرت بررسی شود.

متغیر RH_PRECUNEUS_GVOL (حجم پرکونئوس راست):

- **میانگین:** ۰۶.۹۲۶۷ **میانه:** ۰۰.۹۲۲۸
- **انحراف معیار:** ۴۵.۱۵۴۰
- **چارک اول:** ۰۰.۸۳۷۴ **چارک سوم:** ۰۰.۱۰۱۹۲
- **دامنه بین‌چارکی :(IQR)** ۰۰.۱۸۱۸

الگوی مهم: نیم کره راست حجم بزرگ‌تری دارد (عدم تقارن طبیعی مغز)؛ توزیع تقریباً متقارن است.

متغیر NACCBMI (شاخص توده بدنی):

- **میانگین:** ۵۰.۲۹ **میانه:** ۵۰.۲۶
- **انحراف معیار:** ۸۵.۳۳
- **چارک اول:** ۶۰.۲۳ **چارک سوم:** ۲۰.۳۰
- **دامنه بین‌چارکی :(IQR)** ۶۰.۶

الگوی مهم: میانگین (۵.۲۹) به دلیل داده پرت ۲۰.۷۱۹ (کد خطا) از میانه (۵.۲۶) فاصله گرفته است. بنابراین **میانه و IQR** معیار مناسب‌تری هستند.

متغیر MOCATOTS (نمره کل :(MoCA

- **میانگین:** ۶۵.۲۴ **میانه:** ۴۰.۲۵
- **انحراف معیار:** ۷۵.۵
- **چارک اول:** ۰۰.۲۳ **چارک سوم:** ۰۰.۲۷
- **دامنه بین‌چارکی :(IQR)** ۰۰.۴

الگوی مهم: مقدار حداکثر ۸۸ برای نمره MoCA (دامنه طبیعی ۰–۳۰) کد خطا است. پس از حذف آن، **میانه و IQR** مناسب‌ترند.

متغیر NACCAAAS (شدت افسردگی):

- **میانگین:** ۰.۶۰ **میانه:** ۰.۰۰
- **انحراف معیار:** ۲.۴۰
- **چارک اول:** ۰.۰۰ **چارک سوم:** ۰.۰۰
- **دامنه بین‌چارکی (IQR):** ۰.۰۰

الگوی مهم: بیش از ٪۷۵ افراد نمره ۰ دارند (Q۳ = ۰)؛ توزیع به شدت راست‌چوله است. بنابراین **میانه** (۰) به‌همراه **IQR** (۰) مناسب‌ترین توصیف است.

نتیجه‌گیری نهایی

- برای متغیرهای متقارن (**NACCAGE**، **LH_ENTORHINAL_AVGTH**، **LH_PRECUNEUS_GVOL**، **RH_PRECUNEUS_GVOL**): میانگین و انحراف معیار مناسب هستند.
- برای متغیرهای راست‌چوله یا دارای داده پرت (**EDUC**، **NACCGDS**، **CDRSUM**، **NACCBMI**، **MO-CATOTS**، **NACCAAAS**): میانه و IQR مناسب‌ترند.
- برای متغیرهای حجم مغزی (**LH_ENTORHINAL_GVOL**، **LH_PARAHIPPOCAMPAL_GVOL**، **RH_PARAHIPPOCAMPAL_GVOL**): میانگین و میانه نزدیک‌اند، اما به دلیل وجود داده‌های پرت، گزارش هر دو دسته معیار توصیه می‌شود.

۸ مصورسازی درست

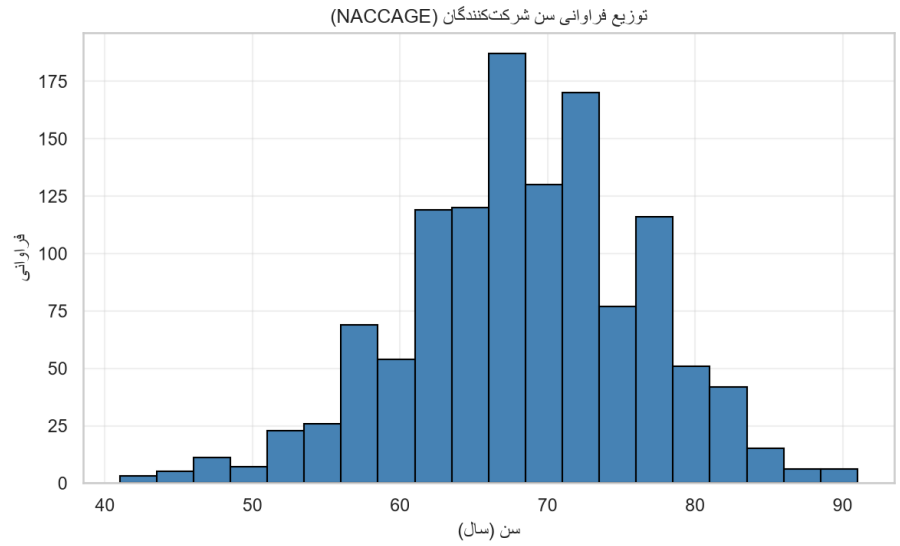
برای انتخاب نوع نمودار، ابتدا نوع متغیر را در نظر می‌گیریم:

- **متغیر کمی (Continuous):** هیستوگرام، نمودار جعبه‌ای، نمودار پراکندگی.
- **متغیر طبقه‌ای (Categorical):** نمودار میله‌ای (Bar chart) یا نمودار دایره‌ای (Pie chart) در صورت تعداد کم دسته‌ها.
- **ترکیب کمی و طبقه‌ای:** نمودار جعبه‌ای گروه‌بندی‌شده (Grouped boxplot).

همچنین از نمایش‌های گمراه‌کننده مانند نمودار سه‌بعدی، برش نامناسب محور، یا پای چارت با دسته‌های زیاد پرهیز می‌شود.

نمودار ۱: هیستوگرام سن (NACCAGE)

نوع متغیر: کمی (پیوسته)
نوع نمودار: هیستوگرام
محور X: سن (سال)
محور Y: فراوانی (تعداد افراد)
عنوان: توزیع فراوانی سن شرکت‌کنندگان (NACCAGE)

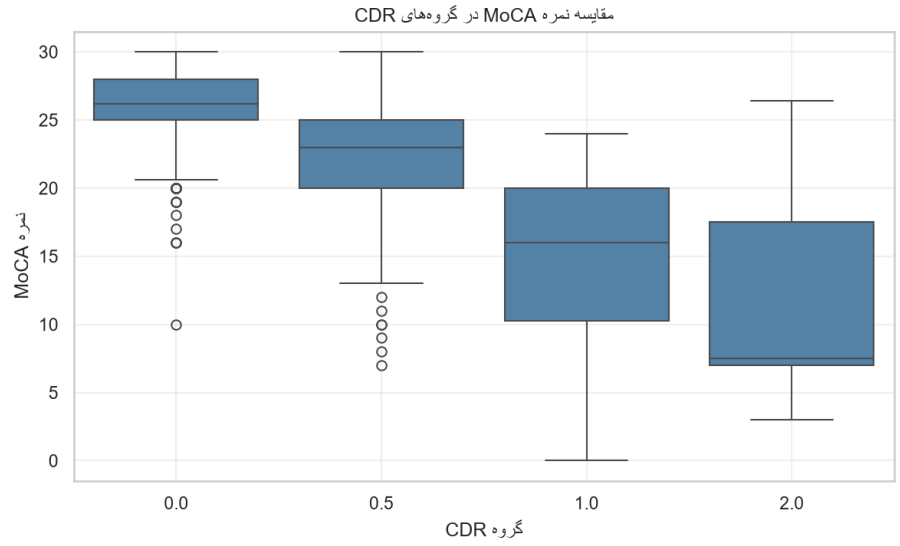


شکل ۴: هیستوگرام توزیع سن شرکت‌کنندگان. محور افقی سن (سال) و محور عمودی فراوانی است.

تفسیر: توزیع سن تقریباً زنگوله‌ای و متقارن است و بیشتر افراد در بازه ۶۰ تا ۷۵ سال قرار دارند. این نمودار برای نمایش توزیع یک متغیر کمی پیوسته مناسب است و از برش نامناسب محور (مثلاً شروع از ۵۰) پرهیز شده است.

نمودار ۲: نمودار جعبه‌ای نمره MoCA بر حسب گروه CDR

نوع متغیر: ترکیب کمی (MOCATOTS) و طبقه‌ای (CDRGLOB)
نوع نمودار: نمودار جعبه‌ای گروه‌بندی‌شده (Boxplot)
محور X: گروه CDR (۰ = سالم، ۰.۵ = اختلال شناختی خفیف، ۱ = دمانس خفیف)
محور Y: نمره کل MoCA (MOCATOTS)
عنوان: مقایسه نمره MoCA در گروه‌های مختلف CDR

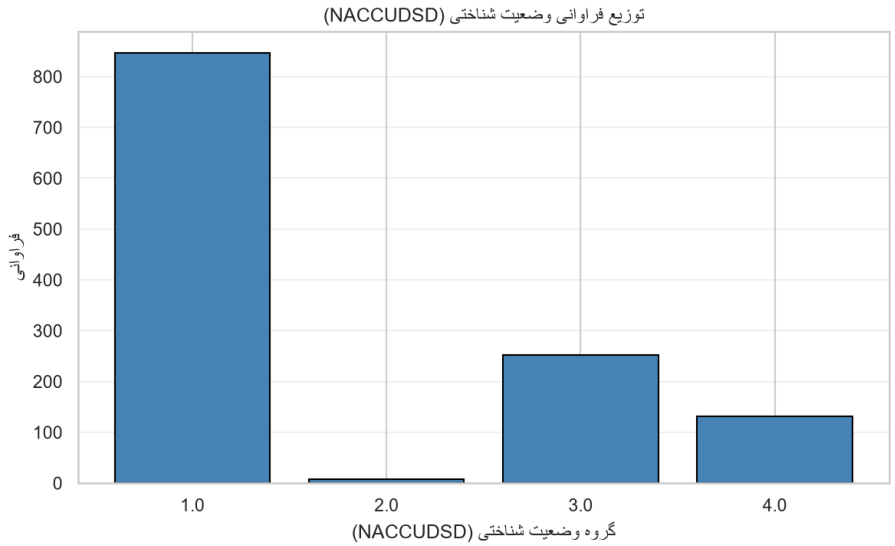


شکل ۵: نمودار جعبه‌ای نمره MoCA بر حسب گروه CDR. محور افقی گروه CDR و محور عمودی نمره MoCA است.

تفسیر: با افزایش شدت اختلال شناختی (از CDR = ۰ به CDR = ۱)، میانه نمره MoCA کاهش می‌یابد. این نمودار برای مقایسه توزیع یک متغیر کمی در چند گروه مناسب است و از نمایش سه‌بعدی یا جعبه‌های بدون توضیح پرهیز شده است.

نمودار ۳: نمودار میله‌ای وضعیت شناختی (NACCUDSD)

نوع متغیر: طبقه‌ای (اسمی)
نوع نمودار: نمودار میله‌ای (Bar chart)
محور X: گروه وضعیت شناختی (NACCUDSD)
محور Y: فراوانی (تعداد افراد)
عنوان: توزیع فراوانی وضعیت شناختی شرکت‌کنندگان (NACCUDSD)

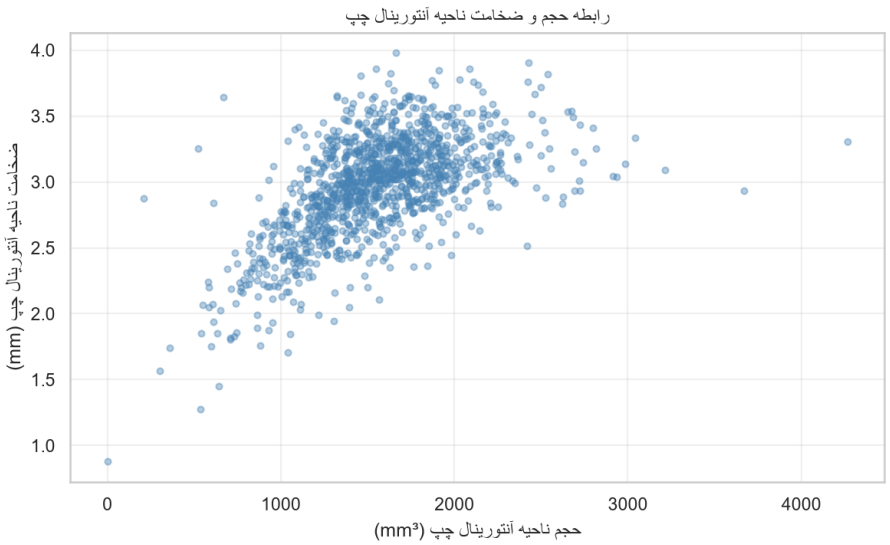


شکل ۶: نمودار میله‌ای وضعیت شناختی. محور افقی گروه‌های NACCUDSD و محور عمودی فراوانی است.

تفسیر: گروه ۱ (سالم/طبیعی) با ۸۴۷ نفر (۴۷٪.۰۶۸) بیشترین فراوانی را دارد. نمودار میله‌ای برای متغیرهای طبقه‌ای مناسب است و از پای چارت (که برای دسته‌های زیاد گمراه‌کننده است) پرهیز شده است.

نمودار ۴: نمودار پراکندگی حجم و ضخامت ناحیه آنتورینال

نوع متغیر: دو متغیر کمی (پیوسته)
نوع نمودار: نمودار پراکندگی (Scatter plot)
محور X: حجم ناحیه آنتورینال چپ (LH_ENTORHINAL_GVOL) — واحد: میلی‌متر مکعب
محور Y: ضخامت ناحیه آنتورینال چپ (LH_ENTORHINAL_AVGTH) — واحد: میلی‌متر
عنوان: رابطه بین حجم و ضخامت ناحیه آنتورینال چپ



شکل ۷: نمودار پراکندگی حجم و ضخامت ناحیه آنتورینال چپ. محور افقی حجم (mm^3) و محور عمودی ضخامت (mm) است.

تفسیر: رابطه مثبت ضعیف تا متوسط بین حجم و ضخامت ناحیه آنتورینال دیده می‌شود. نمودار پراکندگی برای بررسی رابطه دو متغیر کمی مناسب است و از نمایش سه‌بعدی یا برش نامناسب محور پرهیز شده است.

نتیجه‌گیری

- **هیستوگرام** برای نمایش توزیع متغیر کمی (NACCAGE) مناسب است.
- **نمودار جعبه‌ای** برای مقایسه توزیع کمی در گروه‌های طبقه‌ای MoCA) در گروه‌های (CDR مناسب است.
- **نمودار میله‌ای** برای نمایش فراوانی متغیر طبقه‌ای (NACCUDSD) مناسب است.
- **نمودار پراکندگی** برای بررسی رابطه بین دو متغیر کمی (حجم و ضخامت آنتورینال) مناسب است.
- در تمام نمودارها از نمایش‌های گمراه‌کننده (سه‌بعدی، برش نامناسب محور، پای چارت با دسته‌های زیاد) پرهیز شده است.

۹ مقایسه توصیفی اولیه

در این بخش، متغیرهای کمی را بین گروه‌های مختلف به صورت **صرفاً توصیفی** مقایسه می‌کنیم. در این مرحله هیچ آزمون استنباطی (مانند t-test یا ANOVA) انجام نمی‌شود و هیچ ادعایی درباره معناداری آماری مطرح نمی‌گردد. هدف فقط مشاهده الگوهای اولیه در داده‌ها است.

مقایسه ۱: نمره MoCA (MOCATOTS) بین گروه‌های وضعیت شناختی (NACCUDSD)

متغیر کمی **MOCATOTS** (نمره کل MoCA) را بین چهار گروه **NACCUDSD** مقایسه می‌کنیم. مقادیر کد خطا (نمره ۸۸) از متغیر حذف شده‌اند.

جدول ۵: مقایسه توصیفی نمره MoCA بین گروه‌های وضعیت شناختی (NACCUDSD)

گروه NACCUDSD	N	میانگین	میانه	انحراف معیار	Q۱	Q۳
گروه ۱ (سالم/طبیعی)	۸۴۶	۲۳.۲۶	۲۰.۲۶	۴۹.۲	۰۰.۲۵	۰۰.۲۸
گروه ۲ (نادر)	۷	۲۶.۲۶	۸۰.۲۶	۶۶.۲	۸۰.۲۵	۷۰.۲۷
گروه ۳ (اختلال خفیف)	۲۵۲	۴۵.۲۲	۰۰.۲۳	۴۵.۳	۰۰.۲۰	۰۰.۲۵
گروه ۴ (زوال عقل)	۱۲۸	۴۸.۱۶	۰۰.۱۷	۱۰.۶	۰۰.۱۳	۰۰.۲۱

الگوی مهم (توصیفی): گروه‌های ۱ و ۲ میانگین تقریباً یکسانی دارند (۲۳.۲۶ و ۲۶.۲۶)؛ اما گروه ۲ فقط ۷ نفر دارد و قابل اتکا نیست. با حرکت به گروه ۳ (اختلال خفیف) و سپس گروه ۴ (زوال عقل)، میانگین و میانه نمره MoCA به‌طور پیوسته کاهش می‌یابد (از ۴۵.۲۲ به ۴۸.۱۶). این الگو با انتظار بالینی سازگار است، اما در این مرحله فقط توصیف می‌شود و نه استنباط.

مقایسه ۲: حجم ناحیه آنتورینال (LH_ENTORHINAL_GVOL) بین گروه‌های CDR- CDR GLOB)

متغیر کمی **LH_ENTORHINAL_GVOL** را بین گروه‌های **CDRGLOB** مقایسه می‌کنیم.

جدول ۶: مقایسه توصیفی حجم ناحیه آنتورینال چپ بین گروه‌های CDR

گروه CDRGLOB	N	میانگین	میانه	انحراف معیار	Q۱	Q۳
CDR = ۰.۰ (سالم)	۸۰۰	۲۶.۱۶۰۱	۰۰.۱۵۸۰	۹۰.۳۷۵	۷۵.۱۳۷۶	۲۵.۱۸۲۱
CDR = ۵.۰ (MCI)	۳۶۸	۷۲.۱۴۷۶	۵۰.۱۴۴۹	۱۷.۴۶۱	۲۵.۱۱۷۳	۵۰.۱۷۱۶
CDR = ۰.۱ (زوال عقل خفیف)	۶۰	۸۵.۱۴۳۰	۰۰.۱۳۱۳	۵۹.۵۰۲	۵۰.۱۱۰۳	۲۵.۱۷۲۹
CDR = ۰.۲ (زوال عقل متوسط)	۹	۴۴.۱۳۷۱	۰۰.۱۳۸۳	۳۲.۱۹۷	۰۰.۱۲۶۶	۰۰.۱۴۸۲

الگوی مهم (توصیفی): میانگین حجم ناحیه آنتورینال از ۲۶.۱۶۰۱ در گروه سالم به ۴۴.۱۳۷۱ در گروه زوال عقل متوسط کاهش می‌یابد. میانه نیز روند نزولی مشابهی دارد (از ۱۵۸۰ به ۱۳۸۳)، هرچند در گروه CDR = ۰.۱ میانه (۱۳۱۳) پایین‌تر از گروه CDR = ۰.۲ (۱۳۸۳) است — که به دلیل حجم نمونه بسیار کوچک گروه CDR = ۰.۲ (۹ نفر) و پراکندگی بالای گروه CDR = ۰.۱ (SD = ۵۹.۵۰۲) است. این الگو با انتظار بالینی درباره تحلیل ناحیه آنتورینال در زوال عقل سازگار است، اما در این مرحله صرفاً توصیف می‌شود.

نتیجه‌گیری توصیفی

- **نمره MoCA** با شدت اختلال شناختی (NACCUDSD) رابطه معکوس توصیفی نشان می‌دهد (از ۲۳.۲۶ در سالم به ۴۸.۱۶ در زوال عقل).
- **سن** در دو جنس اختلاف توصیفی کوچکی دارد (میانگین ۹۹.۶۸ در برابر ۶۶.۶۷) و توزیع‌ها همپوشانی زیادی دارند.

- **حجم ناحیه آنتورینال** با افزایش شدت زوال عقل (CDRGLOB) کاهش توصیفی نشان می‌دهد (از ۱۶۰۱ به ۱۳۷۱)، هرچند گروه CDR = ۰.۲ با ۹ نفر بسیار کوچک است.
- هیچ کدام از این مقایسه‌ها ادعای استنباطی (معناداری آماری) ندارند و فقط برای مشاهده الگوهای اولیه ارائه شده‌اند.

۱۰ نهایی کردن سوال آماری

سوال اصلی (اولیه)

سوال اولیه‌ای که در ابتدا مطرح بود به این صورت بود که:

> «آیا بین حجم/ضخامت ناحیه آنتورینال و وضعیت شناختی یعنی کدهای NACCUDSD یا CDRGLOB (یا زوال عقل) رابطه وجود دارد؟»

این سوال بسیار کلی است و داده‌های موجود اجازه پاسخ دقیق به آن را نمی‌دهند، زیرا:

- متغیرهای زیادی (سن، تحصیلات، افسردگی، بیماری‌های همراه، حجم نواحی دیگر مغز) با هم تغییر می‌کنند و تفکیک اثر آنتورینال از آن‌ها بدون مدل‌سازی چندمتغیره ممکن نیست.
- داده‌ها مقطعی (Cross-sectional) هستند و رابطه علت‌ومعلولی را نشان نمی‌دهند.

سوال نهایی (محدودتر و دقیق‌تر)

با توجه به شناخت حاصل از تحلیل توصیفی (سوال‌های ۶ تا ۹)، سوال آماری را به صورت زیر نهایی و محدود می‌کنیم:

> **«آیا میانگین ضخامت (یا حجم) ناحیه آنتورینال چپ بین گروه‌های وضعیت شناختی (NACCUDSD) یا گروه‌های CDR (CDRGLOB) تفاوت دارد؟»**

به عبارت دقیق‌تر، سوال به دو بخش تقسیم می‌شود:

۱. **مقایسه میانگین/میانه `LH_ENTORHINAL_AVGTH` بین گروه‌های `NACCUDSD` (سالم، MCI، زوال عقل).**

۲. **مقایسه میانگین/میانه `LH_ENTORHINAL_GVOL` بین گروه‌های `CDRGLOB` (سالم، MCI، زوال عقل خفیف، زوال عقل متوسط).**

چرا داده‌ی موجود برای پاسخ به این سوال مناسب است؟

- **وجود متغیرهای پیامد و پیش‌بین به‌صورت هم‌زمان:** در فایل `udslong_imputed.csv` متغیرهای وضعیت شناختی (NACCUDSD، CDRGLOB، CDRSUM) و در فایل `mriscanclean.csv` متغیرهای حجم و ضخامت ناحیه آنتورینال (LH_ENTORHINAL_GVOL، LH_ENTORHINAL_AVGTH) موجود است؛ بنابراین امکان مقایسه گروهی فراهم است.
- **حجم نمونه کافی:** ۱۲۳۷ نفر در هر دو فایل وجود دارد که برای مقایسه توصیفی و حتی آزمون‌های استنباطی (در صورت نیاز) کافی است.

- **توزیع متغیرها مناسب است:** در سوال ۷ دیدیم که LH_ENTORHINAL_AVGTH توزیع تقریباً نرمال دارد و LH_ENTORHINAL_GVOL نیز با وجود داده‌های پرت، تقارن نسبی دارد؛ بنابراین استفاده از میانگین برای مقایسه گروهی قابل توجیه است (و در صورت لزوم، میانه به‌عنوان معیار مقاوم گزارش می‌شود).
- **گروه‌بندی معنادار:** متغیر NACCUDSD چهار گروه (سالم، نادر، اختلال خفیف، زوال عقل) و CDRGLOB چهار گروه (۰، ۰.۵، ۱، ۲) دارد که امکان مقایسه چندگروهی را فراهم می‌کند.
- **الگوی اولیه در داده‌ها دیده می‌شود:** در سوال ۹ مشاهده کردیم که با افزایش شدت اختلال شناختی، میانگین حجم ناحیه آنتورینال کاهش می‌یابد (از ۱۶۰۱ به ۱۳۷۱). این الگو انگیزه‌ی کافی برای طرح سوال دقیق‌تر فراهم می‌کند.
- **عدم نیاز به داده‌های اضافی:** برای پاسخ به این سوال، نیازی به داده‌های طولی (Longitudinal) یا آزمایشگاهی اضافی نیست؛ همان داده‌های مقطعی موجود کافی است.

محدودیت‌ها و آنچه داده‌ی موجود برای آن مناسب نیست

- **ادعای علت‌ومعلولی:** داده‌ها مقطعی هستند و نمی‌توان گفت «کاهش ضخامت آنتورینال باعث زوال عقل می‌شود» یا برعکس.
- **تفکیک اثر آنتورینال از سایر نواحی مغز:** بدون مدل‌سازی چندمتغیره (مثلاً رگرسیون با کنترل سن، تحصیلات، افسردگی) نمی‌توان گفت اثر آنتورینال مستقل از سایر متغیرهاست.
- **پیش‌بینی:** داده‌ها برای ساخت مدل پیش‌بینی (Prediction) طراحی نشده‌اند؛ هدف توصیفی/مقایسه‌ای است.

جمع‌بندی

سوال آماری نهایی، محدود به «**مقایسه توصیفی (و در صورت لزوم استنباطی) میانگین ضخامت/حجم ناحیه آنتورینال چپ بین گروه‌های وضعیت شناختی**» است. داده‌های موجود (۱۲۳۷ نمونه، وجود هم‌زمان متغیرهای MRI و شناختی، توزیع مناسب و گروه‌بندی معنادار) برای پاسخ به این سوال **کاملاً مناسب** هستند، در حالی که برای ادعای علت‌ومعلولی یا تفکیک اثر سایر متغیرها کافی نیستند و نیاز به تحلیل چندمتغیره یا داده‌های طولی دارند.

ج۱: نقشه زیرمجموعه UDS و MRI و دسته‌بندی متغیرها

فایل‌های تحویلی:

- udslong_imputed.csv: داده‌های طولی UDS پس از imputation، شامل متغیرهای جمعیت‌شناختی، پزشکی، عملکردی و شناختی.
- mriscanclean.csv: داده‌های MRI شامل حجم و ضخامت نواحی مختلف قشر مغز (چپ و راست).

دسته‌بندی متغیرهای UDS:

- **جمعیت‌شناختی:** SEX، NACCAGE، EDUC، HISPANIC، RACE، PRIMLANG، MARISTAT، NACCLIVS.

- **پزشکی:** HYPERTEN، DIABETES، CVHATT، CVAFIB، CBSTROKE، CBTIA، APNEA، THYROID، B12DEF، NACCBMI، HEIGHT، WEIGHT، BPSYS، BPDIAS، HRATE، TOBAC30، TOBAC100، ALCOHOL.

- **عملکردی:** INDEPENDENT، NACCNIHR، BILLS، TAXES، SHOPPING، GAMES، STOVE، MEALPREP، EVENTS، PAYATTN، REMDATES، TRAVEL، HOMEHOBB، PERSCARE.

- **شناختی:** NACCUDSD، CDRGLOB، CDRSUM، MOCATOTS، NACCAPOE، NACCAAAS، NACCGDS، MEMORY، ORIENT، JUDGMENT، COMMUN.

متغیرهای MRI:

- **حجم (GVOL):** LH_ENTORHINAL_GVOL، RH_ENTORHINAL_GVOL، LH_PARAHIPPOCAMPAL_GVOL، LH_PRECUNEUS_GVOL و ... (سایر نواحی قشر مغز در چپ و راست). واحد: میلی‌متر مکعب (mm^3).

- **ضخامت (AVGTH):** LH_ENTORHINAL_AVGTH، RH_ENTORHINAL_AVGTH و ... (سایر نواحی). واحد: میلی‌متر (mm).

- **مثال:** LH_ENTORHINAL_GVOL حجم ناحیه آنتورینال چپ را نشان می‌دهد (اندازه‌گیری حجم بافت) و LH_ENTORHINAL_AVGTH میانگین ضخامت قشر در همان ناحیه را نشان می‌دهد (اندازه‌گیری ضخامت قشری).

ج۲: ساختار شرکت‌کننده و مراجعه

تعداد شرکت‌کنندگان یکتا و مراجعه‌ها:

- تعداد شرکت‌کنندگان یکتا (NACCID): **۱۲۳۷ نفر**

- تعداد رکوردها (مراجعه‌ها): **۱۲۳۷ رکورد**

- توزیع تعداد مراجعه به ازای هر شرکت‌کننده: **همه‌ی ۱۲۳۷ شرکت‌کننده دقیقاً یک مراجعه دارند** (فراوانی = ۱ برای هر نفر؛ هیچ‌کس بیش از یک مراجعه ندارد).

نتیجه ساختاری: داده‌ها **مقطعی** (Cross-sectional) هستند؛ یعنی هر شرکت‌کننده فقط یک بار در تحلیل حاضر است و نیازی به قاعده‌ی انتخاب «مشاهده اصلی» نیست، چون هر فرد از ابتدا فقط یک مشاهده دارد.

اهمیت این ساختار برای تحلیل:

- **مزیت:** داده مقطعی، تحلیل توصیفی و مقایسه گروهی را ساده می‌کند و مشکل همبستگی درون‌فردی (Within-subject correlation) وجود ندارد.

- **محدودیت:** نمی‌توان تغییرات درون‌فردی در طول زمان (مثلاً روند افت شناختی) را بررسی کرد؛ برای آن به داده طولی نیاز است.

ج۳: اتصال UDS و MRI

با استفاده از شناسه یکتای NACCID، دو فایل UDS و MRI به هم متصل شدند. نتایج اتصال در جدول زیر گزارش می‌شود:

جدول ۷: گزارش اتصال دو فایل UDS و MRI

شاخص	تعداد
تعداد افراد در فایل UDS	۱۲۳۷
تعداد افراد در فایل MRI	۱۲۳۷
تعداد افراد مشترک (تطابق کامل)	۱۲۳۷
موارد بدون تطابق (فقط در UDS، بدون MRI)	۰
موارد بدون تطابق (فقط در MRI، بدون UDS)	۰
حجم نمونه نهایی چندوجهی	**۱۲۳۷**

تفسیر توصیفی: اتصال دو فایل **کاملاً موفق** بوده است: هر ۱۲۳۷ شرکت‌کننده در فایل UDS، معادل MRI نیز دارند و برعکس. هیچ موردی بدون تطابق (Unmatched) وجود ندارد. بنابراین، حجم نمونه‌ی نهایی چندوجهی برابر با **۱۲۳۷ نفر** است و هیچ داده‌ای به دلیل عدم تطابق حذف نشده است.

پیامد برای تحلیل‌های بعدی:

- **مزیت:** حجم نمونه در تحلیل‌های چندوجهی (که هم متغیرهای UDS و هم متغیرهای MRI را شامل می‌شوند) با حجم نمونه‌ی تک‌وجهی برابر است؛ بنابراین قدرت آماری کاهش نمی‌یابد و نیازی به بررسی سوگیری ناشی از حذف داده (Attrition bias) نیست.
- **یکپارچگی:** تطابق کامل نشان می‌دهد که شناسه NACCID در هر دو فایل به‌درستی و یکسان کدگذاری شده و داده‌ها از یک منبع واحد (NACC) استخراج شده‌اند.

ج۴: داده‌های گمشده و انتخاب نمونه چندوجهی

درصد گمشدگی متغیرهای اصلی UDS:

جدول ۸: درصد گمشدگی متغیرهای اصلی UDS

متغیر	تعداد گمشده	درصد
NACCAGE	۰	۰۰٪.۰۰
EDUC	۰	۰۰٪.۰۰
CDRGLOB	۰	۰۰٪.۰۰
CDRSUM	۰	۰۰٪.۰۰
MOCATOTS	۰	۰۰٪.۰۰
NACCAPOE	۲۷۸	۴۷٪.۰۲۲
NACCBMI	۱۲۶	۱۹٪.۰۱۰
NACCAAAS	۰	۰۰٪.۰۰
NACCGDS	۰	۰۰٪.۰۰

تفسیر: بیشتر متغیرهای اصلی UDS (سن، تحصیلات، نمرات شناختی، حجم و ضخامت آنتورینال) **هیچ داده‌ی گمشده‌ای ندارند.** تنها دو متغیر گمشدگی قابل توجه دارند:

- NACCAPOE: ۴۷٪.۰۲۲ گمشده (کد ۹ = نامشخص). این مقدار زیاد است و در تحلیل‌های مربوط به ژنوتیپ APOE باید با احتیاط برخورد شود؛ یا با روش‌های imputation جایگزین شود یا در تحلیل حذف گردد.
- NACCBMI: ۱۹٪.۰۱۰ گمشده (احتمالاً به دلیل کد ۰۲.۷۱۹ که به‌عنوان مقدار نامعتبر شناسایی شد). این مقدار قابل قبول است و می‌توان با میانه یا میانگین جایگزین کرد.

مقایسه توصیفی افراد دارای MRI با کل نمونه:

جدول ۹: مقایسه توصیفی افراد دارای MRI با کل نمونه UDS

متغیر	گروه	N	میانگین	میانه (انحراف معیار)
NACCAGE	دارای MRI	۱۲۳۷	۱۹.۶۸	۰۰.۶۸ (۰۴.۸)
EDUC	دارای MRI	۱۲۳۷	۳۹.۱۶	۰۰.۱۶ (۲۹.۴)
CDRGLOB	دارای MRI	۱۲۳۷	۲۱.۰	۰۰.۰ (۳۳.۰)

تفسیر توصیفی: از آنجا که **هر ۱۲۳۷ نفر در فایل UDS دارای MRI هستند،** گروه «بدون MRI» وجود ندارد و مقایسه‌ی دو گروه معنایی ندارد. به عبارت دیگر، نمونه‌ی دارای MRI **دقیقاً برابر** با کل نمونه‌ی UDS است. بنابراین:

- هیچ سوگیری انتخاب (Selection bias) ناشی از داشتن یا نداشتن MRI وجود ندارد، چون همه MRI دارند.
- توزیع سن (میانگین ۱۹.۶۸، میانه ۰۰.۶۸)، تحصیلات (میانگین ۳۹.۱۶، میانه ۰۰.۱۶) و CDRGLOB (میانگین ۲۱.۰، میانه ۰۰.۰) در نمونه‌ی دارای MRI، نماینده‌ی کل نمونه است.
- **پیامد:** نتایج تحلیل‌های چندوجهی (که هم UDS و هم MRI را شامل می‌شوند) قابل تعمیم به کل نمونه‌ی ۱۲۳۷ نفری است.

ج۵: خلاصه مشترک شناختی و تصویربرداری

نمره شناختی: MOCATOTS (نمره کل MoCA با میانگین ۶۵.۲۴، میانه ۴۰.۲۵، انحراف معیار ۷۵.۵ و IQR ۰۰.۴ (پس از حذف کد خطای ۸۸).

متغیر کمی MRI: LH_ENTORHINAL_AVGTH (ضخامت ناحیه آنتورینال چپ) با میانگین ۹۷.۲، میانه ۰۲.۳، انحراف معیار ۳۸.۰ و IQR ۴۷.۰ (توزیع تقریباً نرمال).

نقاط غیرعادی:

جدول ۱۰: نقاط غیرعادی متغیرهای کلیدی

متغیر	مقدار پرت	تفسیر
MOCATOTS	۸۸	کد خطا (دامنه طبیعی ۰–۳۰)
MOCATOTS	۰	احتمالاً فرد غیرهمکار
LH_ENTORHINAL_GVOL	۰ و ۴۲۶۵	داده‌های پرت
LH_ENTORHINAL_AVGTH	۸۸.۰ و ۹۸.۳	در محدوده معقول

نمودارها: هیستوگرام سن (سوال ۸)، نمودار جعبه‌ای MoCA بر حسب CDR (سوال ۸)، نمودار میله‌ای وضعیت شناختی (سوال ۸)، نمودار پراکندگی حجم-ضخامت آنتورینال (سوال ۸).